ibimbing

OFFLINE BOOTCAMP DATA ANALYST BACH 4

Uber Fare Forecasting

AHMAD FAIZ ALI AZMI

NOVE2026

Hi I'm Ahmad Faiz Ali Azmi

Informatics Engineering graduate (GPA 3.72/4.00) and ongoing advanced training in Data Analytics. Experienced in software development and teaching assistance

Education

dibimbing 2026 – Now
Offline Bootcamp Data Analyst Bach 4

Universitas Brawijaya 2022 – 2026
Undergraduate Degree in Informatics Engineering

Work Experience

Diskominfo Kabupaten Malang Jul 2025 – Sep 2025
Fullstack Developer Intern

Brawijaya University Feb 2025 – Jul 2025
Laboratory Teaching Assistant of Web Programmer



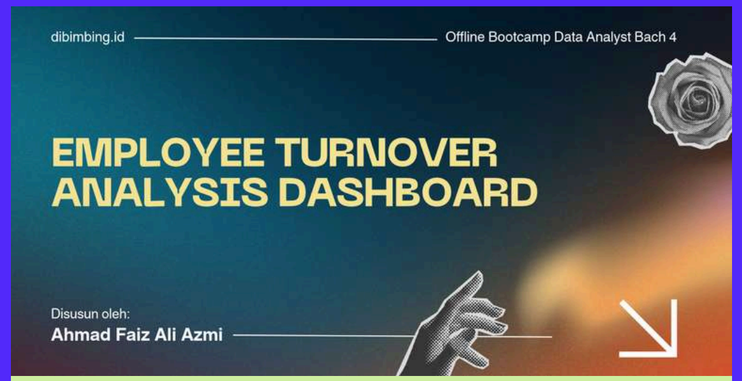
ibimbing



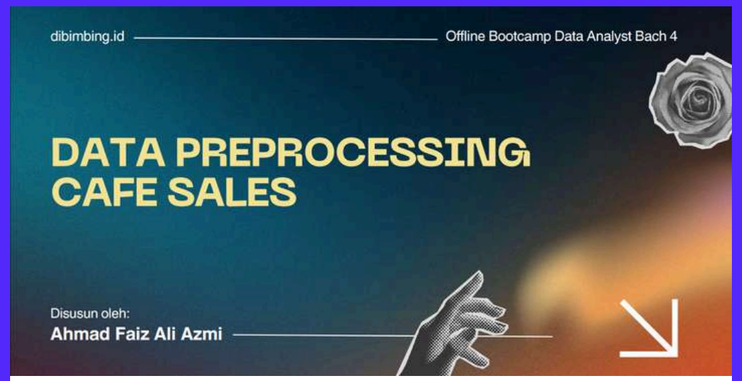
Overview

Overview Project	Statement of the Problem	Data Understanding
Exploratory Data Analysis	Forecasting	Conclusion & Recommendation

Overview Project



Employee Turnover Analysis



Data Prepocessing on Cafe Sales



Exploratory Data Analysis on Cafe Sales



SQL Delivery Performance Analysis



Product & Customer Analytics

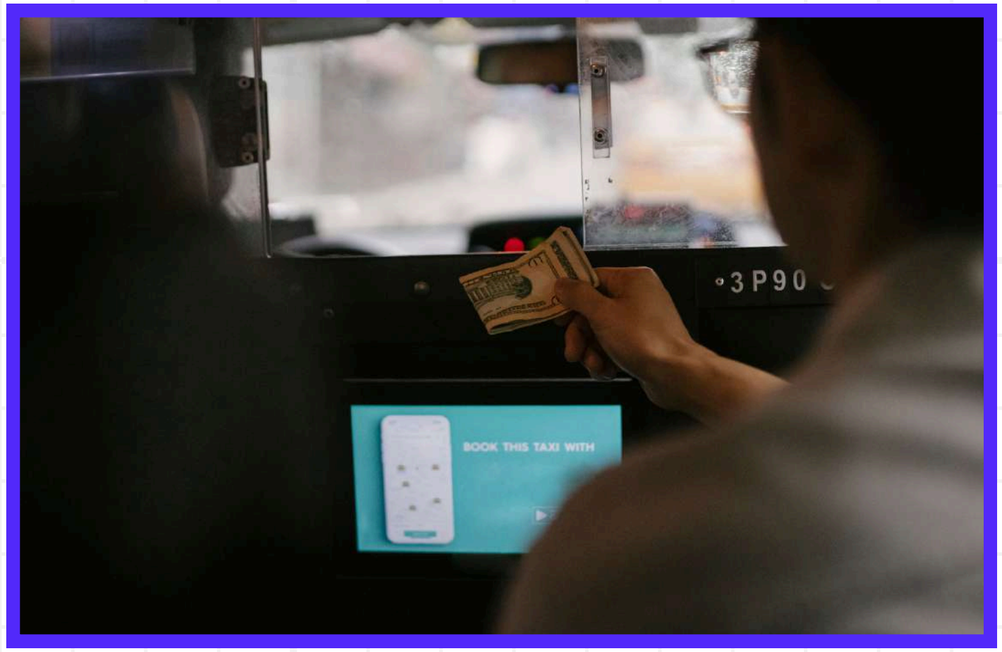


Marketing & Growth Analytics

Statement of the Problem

Perubahan permintaan menjadi salah satu tantangan utama dalam industri ride-hailing. Uber Engineering (2018) mengungkapkan bahwa a**ktivitas perjalanan menunjukkan fluktuasi yang tinggi**, tren yang berubah, serta **pola musiman** mingguan yang membuat kebutuhan operasional sulit diperkirakan. Penelitian Chen et al. (2021) di New York City turut menunjukkan bahwa **permintaan Uber bervariasi menurut waktu dan lokasi**.

Ketidakpastian tersebut juga menjadi tantangan dalam memperkirakan total nilai tarif perjalanan (total fare). Oleh karena itu, diperlukan pendekatan forecasting berbasis data historis untuk mengestimasi total fare harian pada periode mendatang sebagai dasar perencanaan dan pengambilan keputusan yang lebih terukur.



https://www.uber.com/us/en/blog/forecasting-introduction/
https://link.springer.com/article/10.1007/s42421-021-00041-4

ibimbing

Data Understanding

Dataset Uber Fares diperoleh dari Kaggle dan berisi 200.000 sampel perjalanan Uber di New York City pada periode Januari 2009 hingga Juni 2015. Dataset mencakup informasi tarif perjalanan (fare amount), waktu penjemputan, koordinat lokasi penjemputan dan tujuan, serta jumlah penumpang. Setiap baris merepresentasikan satu catatan perjalanan, sehingga data dapat digunakan untuk memahami karakteristik perjalanan dan membentuk agregasi total fare harian untuk analisis time series forecasting.

Data Description

Nama Kolom	Deskripsi
Unnamed: 0	Indeks baris dari file sumber; bukan atribut perjalanan
key	Identifier catatan perjalanan berbasis timestamp
fare_amount	Tarif yang dikenakan untuk satu perjalanan, dalam USD
pickup_datetime	Tanggal dan waktu penjemputan
pickup_longitude	Koordinat longitude lokasi penjemputan
pickup_latitude	Koordinat latitude lokasi penjemputan
dropoff_longitude	Koordinat longitude lokasi tujuan
dropoff_latitude	Koordinat latitude lokasi tujuan
passenger_count	Jumlah penumpang pada perjalanan

	Unnamed: 0	key	fare_amount	pickup_datetime	pickup_longitude	pickup_latitude	dropoff_longitude	dropoff_latitude	passenger_count
0	24238194	2015-05-07 19:52:06.0000003	7.5	2015-05-07 19:52:06 UTC	-73.999817	40.738354	-73.999512	40.723217	1
1	27835199	2009-07-17 20:04:56.0000002	7.7	2009-07-17 20:04:56 UTC	-73.994355	40.728225	-73.994710	40.750325	1
2	44984355	2009-08-24 21:45:00.00000061	12.9	2009-08-24 21:45:00 UTC	-74.005043	40.740770	-73.962565	40.772647	1
3	25894730	2009-06-26 08:22:21.0000001	5.3	2009-06-26 08:22:21 UTC	-73.976124	40.790844	-73.965316	40.803349	3
4	17610152	2014-08-28 17:47:00.000000188	16.0	2014-08-28 17:47:00 UTC	-73.925023	40.744085	-73.973082	40.761247	5

ibimbing

Data Preparation

Mengidentifikasi Tipe Data

	Tipe_Data
Unnamed: 0	int64
key	object
fare_amount	float64
pickup_datetime	object
pickup_longitude	float64
pickup_latitude	float64
dropoff_longitude	float64
dropoff_latitude	float64
passenger_count	int64

Tindakan:

Tipe data kolom pickup_datetime dikonversi menjadi datetime64[ns, UTC]

Inkonsistensi Data

```
Unnamed: 0
key
fare_amount
pickup_datetime
```

Tindakan:

kolom **Unnamed: 0** disesuaikan namanya menjadi **order_id** dan dikonversi ke tipe data *string* guna menjaga konsistensi identitas transaksi

```
==================================================
1. DETEKSI KOORDINAT NOL (0.0)
==================================================
Jumlah baris koordinat bernilai 0.0 : 3968 baris
Persentase terhadap total data      : 1.98%

Contoh baris yang bernilai 0.0:
```

	pickup_longitude	pickup_latitude	dropoff_longitude	dropoff_latitude
7	0.0	0.0	0.0	0.0
11	0.0	0.0	0.0	0.0
65	0.0	0.0	0.0	0.0
92	0.0	0.0	0.0	0.0
120	0.0	0.0	0.0	0.0

Inkonsistensi Data

```
==================================================
2. DETEKSI KOORDINAT TERTUKAR
==================================================
Jumlah baris koordinat tertukar : 102 baris
Persentase terhadap total data  : 0.05%

Contoh baris dengan posisi lintang & bujur terbalik:
```

	pickup_longitude	pickup_latitude	dropoff_longitude	dropoff_latitude
2497	40.746760	-73.982127	40.757287	-73.974800
4376	40.751797	-73.970777	40.719787	-73.992137
4424	40.732897	-73.997740	40.747532	-73.972540
4747	40.770667	-73.961957	40.761672	-73.967237
7367	40.714897	-74.009697	40.726197	-73.994370

Batas bujur dan lintang Kawasan Metropolitan New York (New York metropolitan area) secara astronomis membentang di wilayah berikut:

- **Garis Lintang (Latitude):** Sekitar **39° 30′ LU (Utara) hingga 42° 00′ LU (Utara)**
- **Garis Bujur (Longitude):** Sekitar **72° 00′ BB (Barat) hingga 75° 15′ BB (Barat)**

Tindakan:

Dilakukan penghapusan terhadap koordinat bernilai 0 dan melakukan swap untuk memperbaiki koordinat yang tertukar

ibimbing

Data Preparation

Mengidentifikasi Duplikasi

```
======================================
DUPLIKASI BARIS TOTAL (EXACT MATCH)
======================================
Jumlah baris duplikat identik: 0 baris
```

Mengidentifikasi Missing

	Total Missing	Persentase (%)
Unnamed: 0	0	0.000000
key	0	0.000000
fare_amount	0	0.000000
pickup_datetime	0	0.000000
pickup_longitude	0	0.000000
pickup_latitude	0	0.000000
dropoff_longitude	1	0.000511
dropoff_latitude	1	0.000511
passenger_count	0	0.000000

Tindakan:

data terdapat tepat 1 baris missing value (0,0005%), yaitu pada transaksi indeks ke-87946

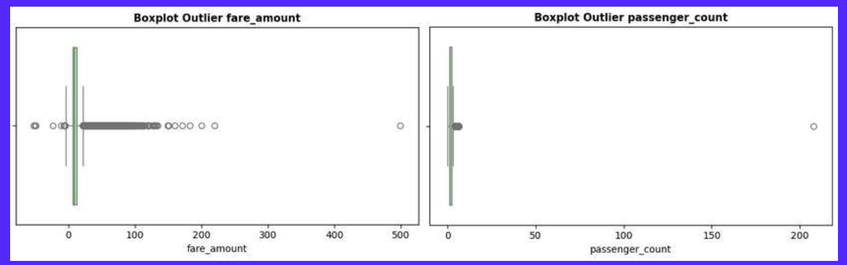
Feature Engineering

```python
# Ekstraksi komponen waktu berdasarkan waktu lokal
df['day'] = df['pickup_datetime_ny'].dt.day
df['day_name'] = df['pickup_datetime_ny'].dt.day_name()
df['day_of_week'] = df['pickup_datetime_ny'].dt.dayofweek
df['month'] = df['pickup_datetime_ny'].dt.month
df['quarter'] = df['pickup_datetime_ny'].dt.quarter
df['year'] = df['pickup_datetime_ny'].dt.year
df['hour'] = df['pickup_datetime_ny'].dt.hour
```

```python
# [Feature Engineering] 8.1 Jarak Tempuh Haversine
def haversine_distance(lon1, lat1, lon2, lat2):
    lon1, lat1, lon2, lat2 = map(np.radians, [lon1, lat1, lon2, lat2])
    dlon = lon2 - lon1
    dlat = lat2 - lat1
    a = np.sin(dlat / 2.0)**2 + np.cos(lat1) * np.cos(lat2) * np.sin(dlon / 2.0)**2
    c = 2 * np.arcsin(np.sqrt(a))
    km = 6371.0 * c
    return km

# Menghitung jarak tempuh garis lengkung bumi antara pickup dan dropoff
df['distance_km'] = haversine_distance(
    df['pickup_longitude'], df['pickup_latitude'],
    df['dropoff_longitude'], df['dropoff_latitude']
)
```

Outlier



Tindakan:

Deteksi nilai ekstrem mengidentifikasi anomali operasional nyata, seperti **tarif bernilai minus dan $0**, tarif ekstrem **$499 dengan jarak 0 km**, serta catatan **kapasitas penumpang di atas 100 orang**. Seluruh anomali ini dibersihkan menggunakan kriteria domain bisnis transportasi: membatasi penumpang pada rentang **0 hingga 6 orang** (Uber Courier s/d UberXL), tarif **$0 < fare < $499**.

Proses filtering mengeliminasi 1.990 baris data anomali dari total 195.745 baris, sehingga menghasilkan dataset akhir **sebanyak 193.755 baris** yang siap digunakan dalam analisis berikutnya.

UBER FARE DASHBOARD

12/31/2008 6/30/2015

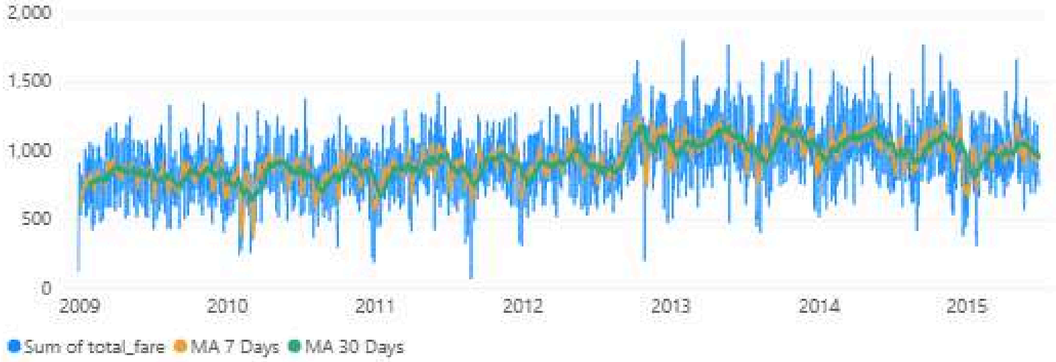
Uber Fare Overview

Fare Forecasting

Avg Daily Total Fare	Avg Daily Trips	Avg Fare per Trip	High-Volatility Days
$924.54	81.65	$11.32	43.32%

Daily Total Fare Trend & Moving Average

Sum of total_fare, MA 7 Days and MA 30 Days by Date



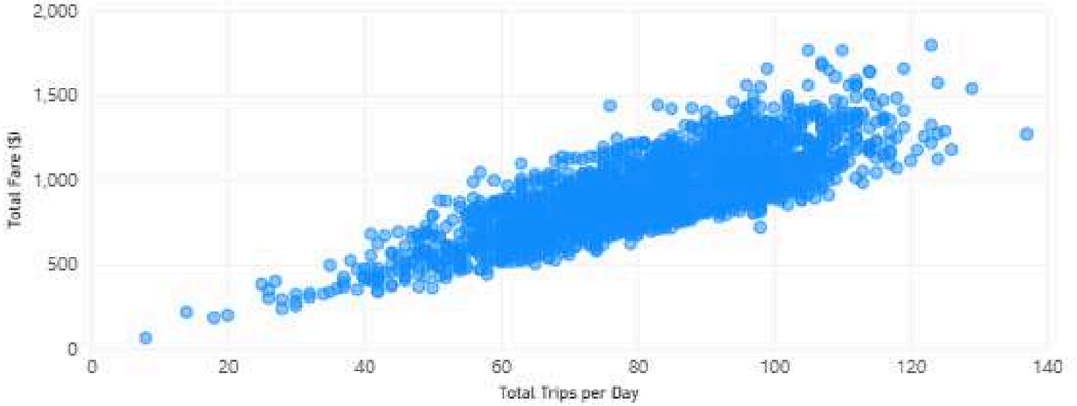
Average Daily Total Fare by Month

Avg Daily Total Fare by MonthName



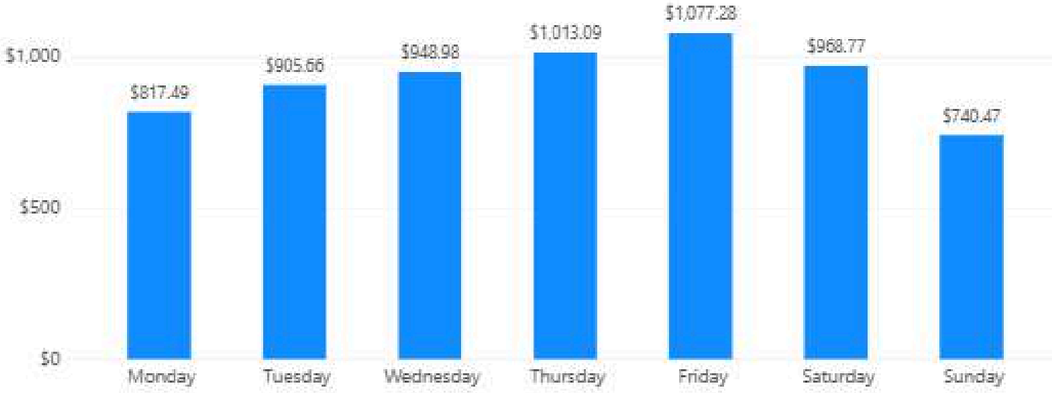
Daily Trips vs Total Fare

Sum of total_trips, Sum of total_fare and Average of avg_fare by Date



Average Daily Total Fare by Day of Week

Avg Daily Total Fare by WeekdayName



Uber

12/31/2008 6/30/2015

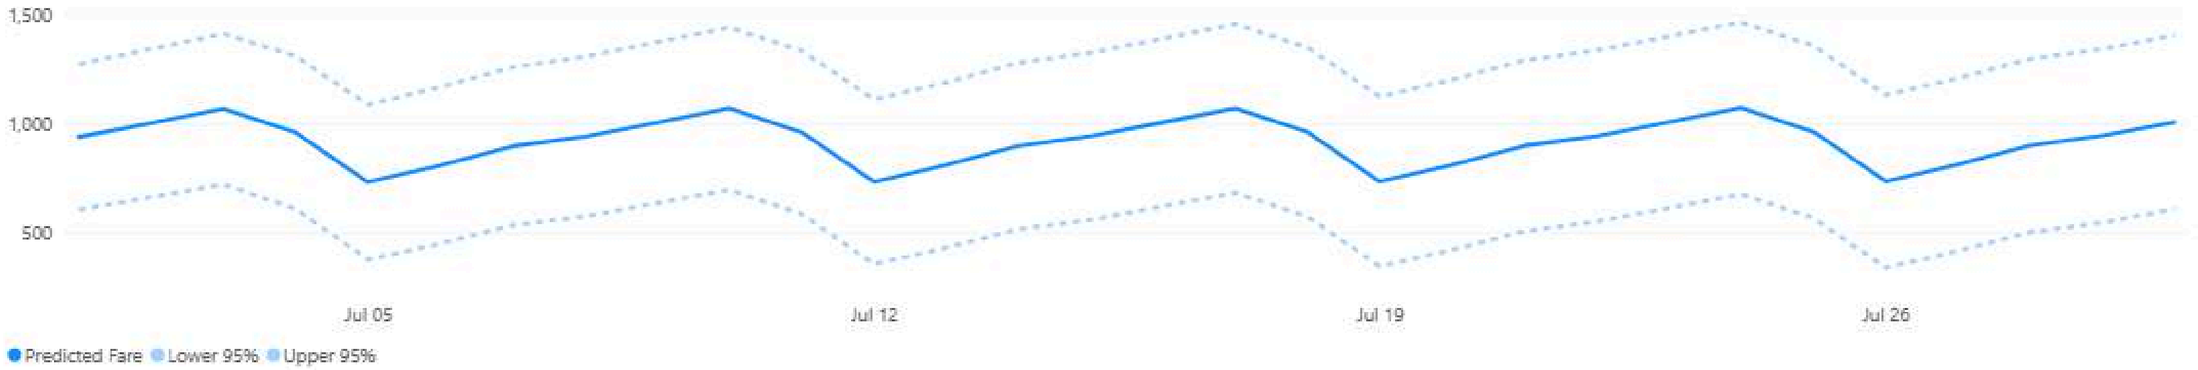
Uber Fare Overview

Fare Forecasting

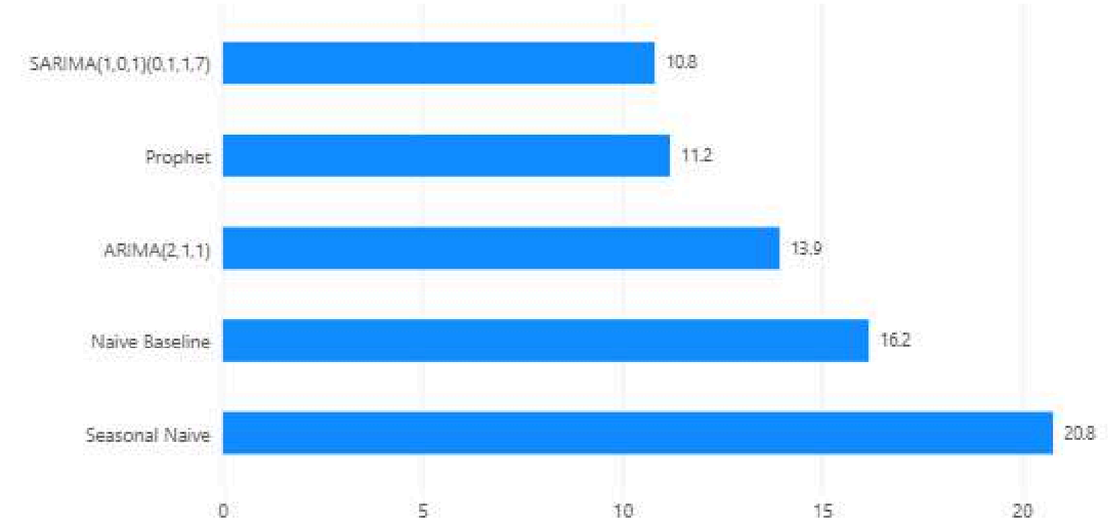
FARE FORECASTING

SARIMA Forecast 30 hari	Forecast Change (%)	SARIMA WAPE	Jumlah Hari yang di Forecast
$27.63K	-3.00%	10.81%	30

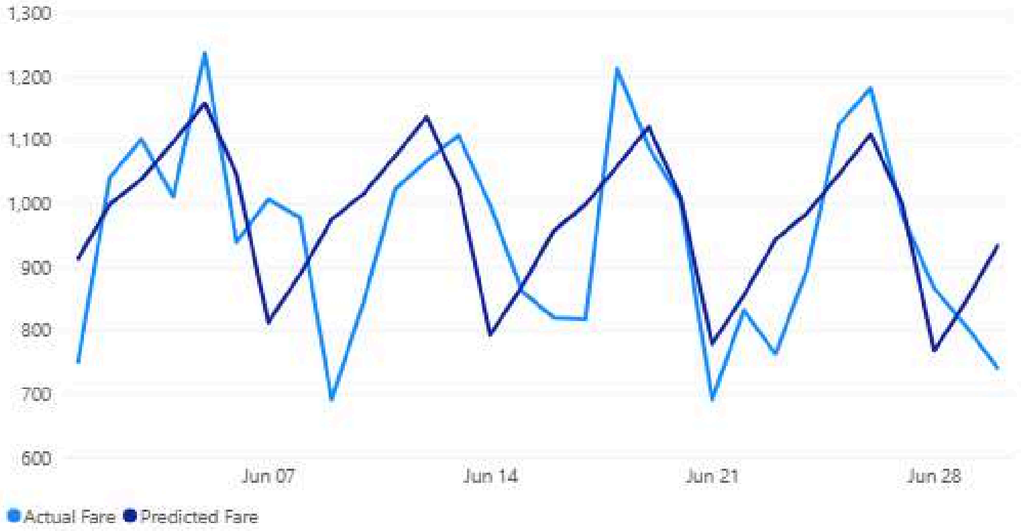
SARIMA 30-Day Fare Forecast



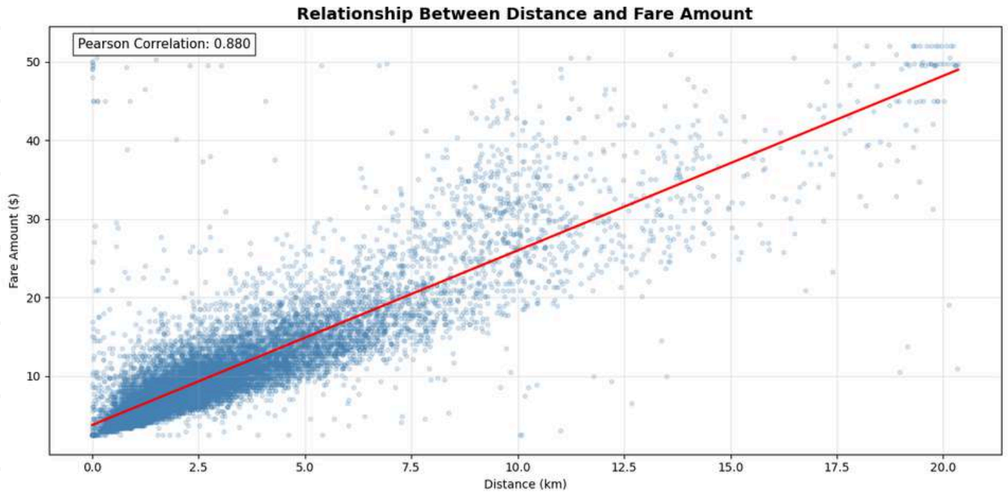
Model Comparison Holdout WAPE (%)

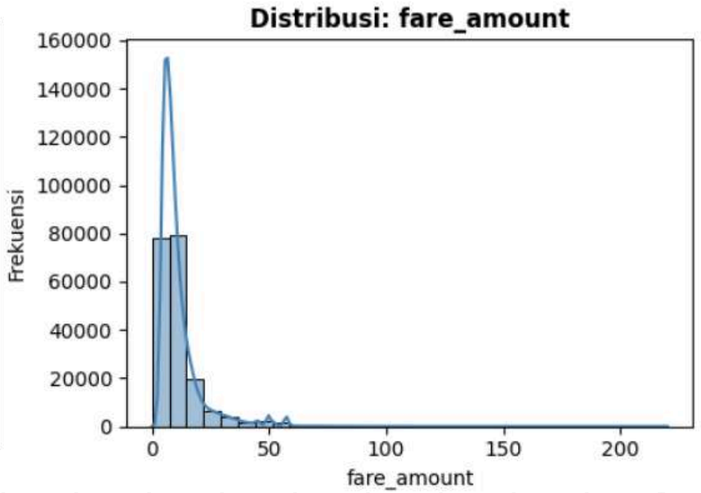


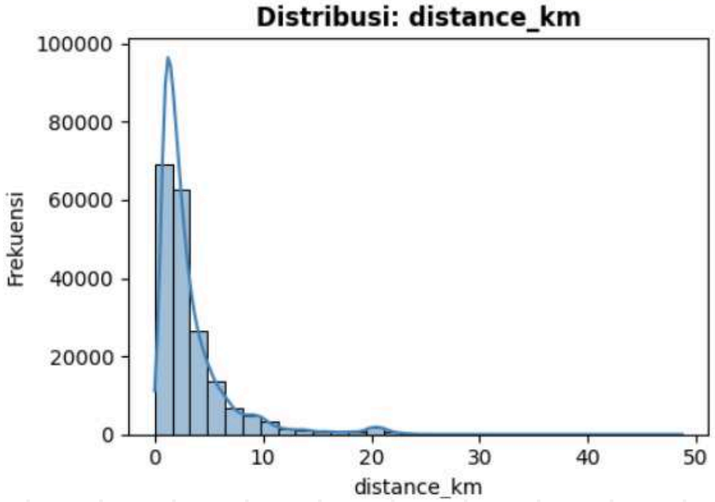
Actual vs Predicted SARIMA Holdout



Karakteristik Order Fare

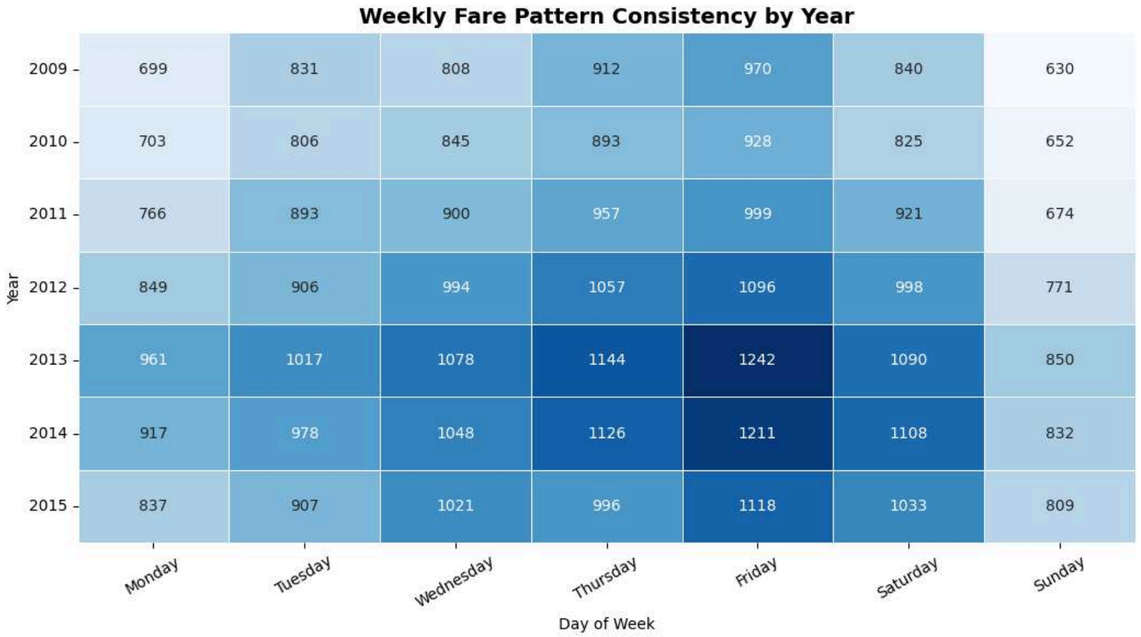


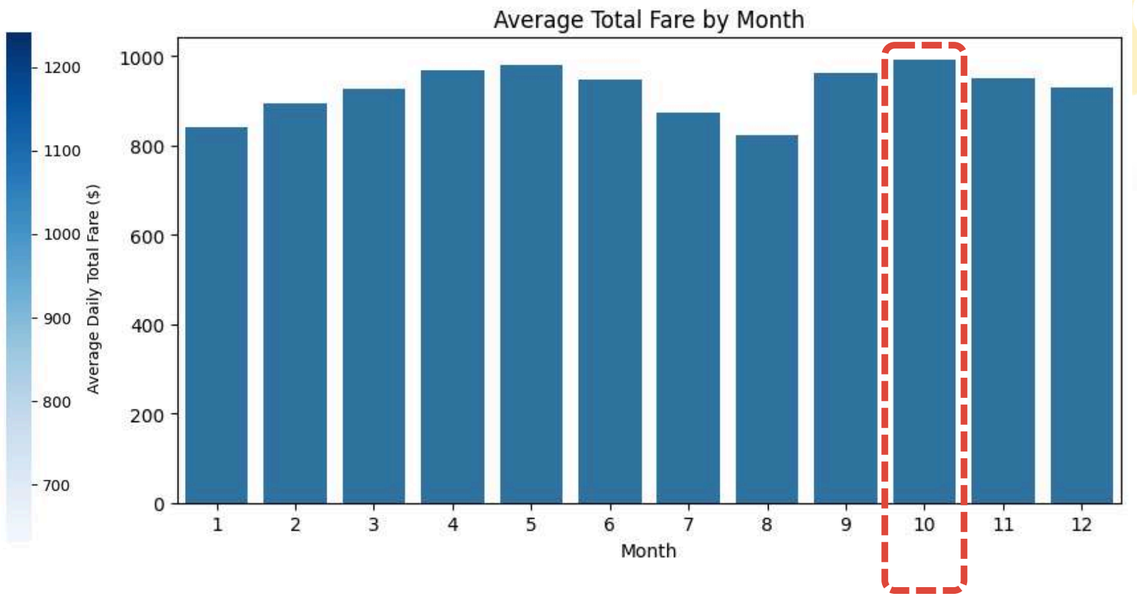




Distribusi fare_amount dan distance_km cenderung right-skewed, menunjukkan bahwa sebagian besar perjalanan memiliki tarif dan jarak relatif rendah, sementara sebagian kecil perjalanan bernilai lebih tinggi. Analisis korelasi Pearson menunjukkan hubungan positif yang kuat antara jarak perjalanan dan tarif (r = 0,88). Hal ini mengindikasikan bahwa jarak merupakan faktor yang berkaitan erat dengan nilai tarif perjalanan, tetapi belum membuktikan bahwa jarak menjadi satu-satunya penentu tarif. Analisis berikutnya memeriksa keterkaitan fitur lain tanpa mengasumsikan hubungan sebab-akibat.

Pola Weekly & Monthly Fare





Analisis pola kalender menunjukkan adanya perbedaan rata-rata total fare berdasarkan hari dan bulan. Friday mencatat rata-rata tertinggi, sedangkan Sunday terendah. Pada tingkat bulanan, October memiliki rata-rata tertinggi sebesar $992,29 dan August terendah sebesar $823,49. Temuan ini mengindikasikan adanya pola temporal yang berulang, terutama pada tingkat mingguan, yang perlu diperhatikan dalam memahami perubahan total fare harian.

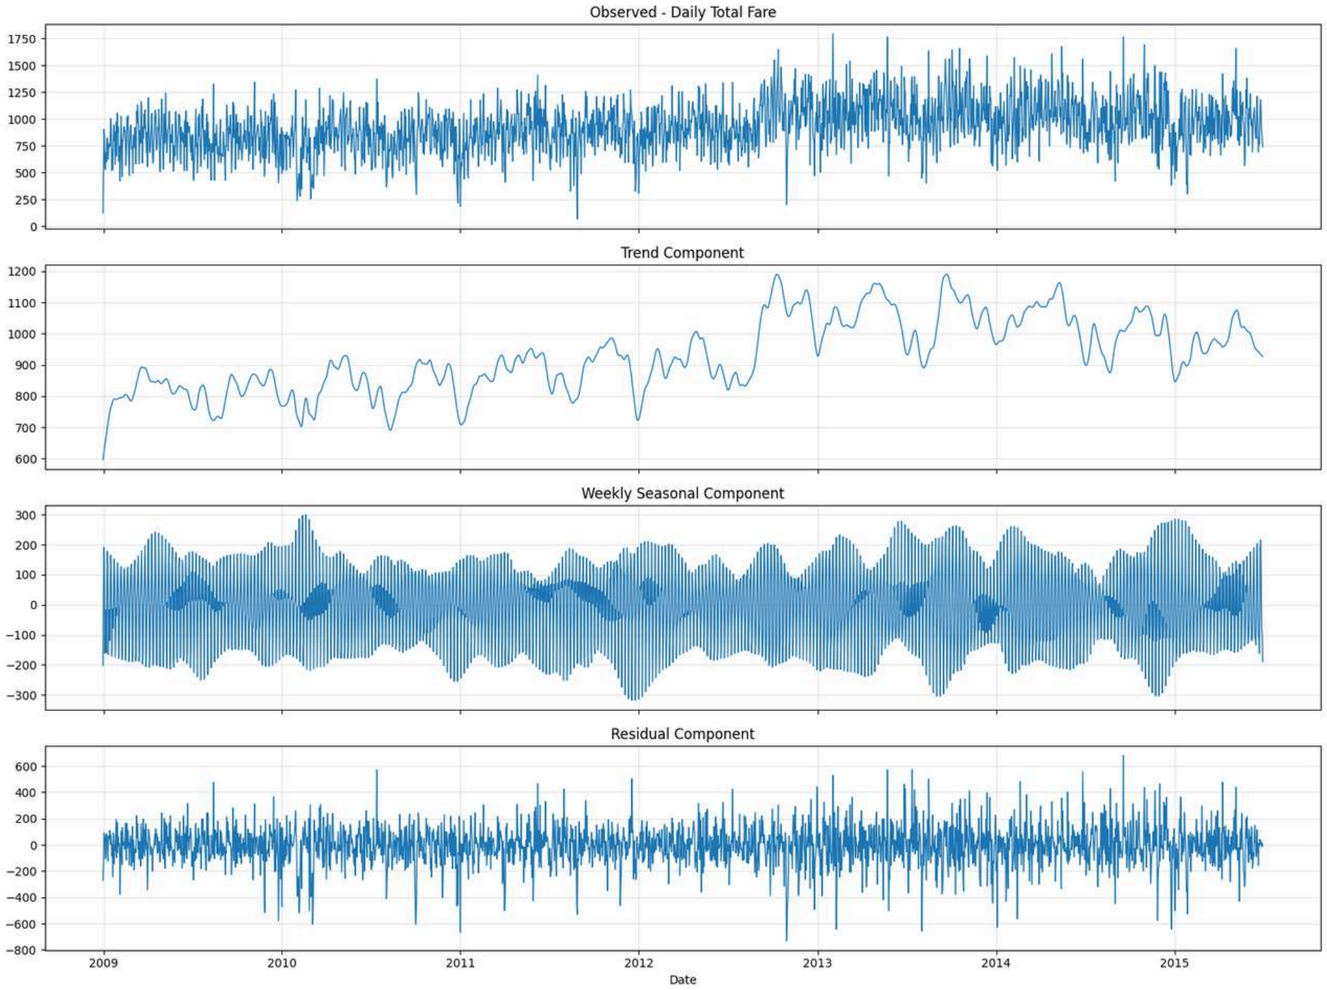


Fare Forecasting

Hasil Exploratory Data Analysis menunjukkan bahwa total fare harian memiliki karakteristik utama: perubahan level historis dan pola kalender yang berulang.

Oleh karena itu, diperlukan pendekatan analisis Timeseries yang mampu mempertimbangkan perubahan level dan pola musiman untuk mengestimasi total fare pada periode mendatang.

Trend, Seasonality & Residual

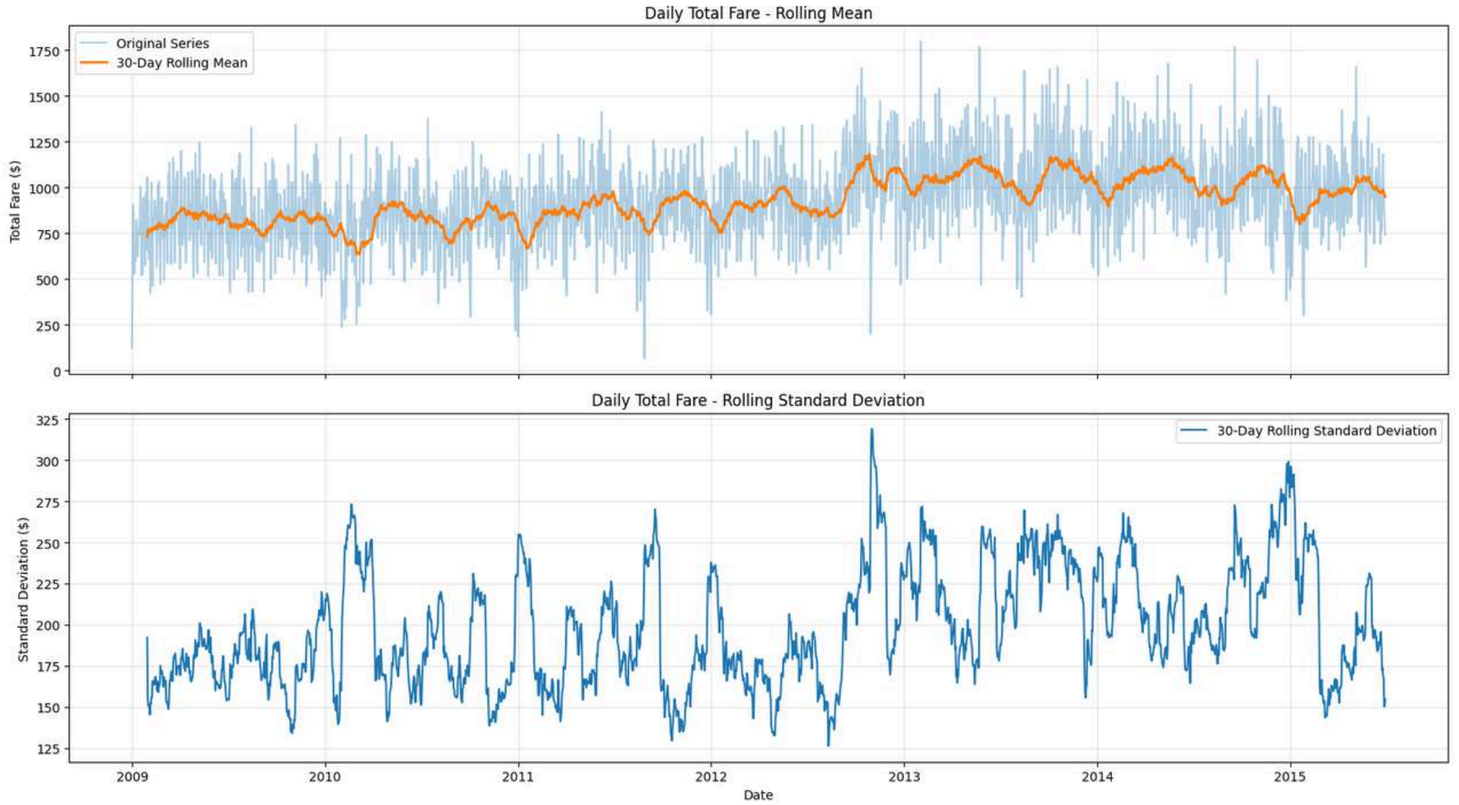


Decomposition dilakukan untuk mengidentifikasi struktur total fare harian dengan memisahkan komponen trend, seasonal, dan residual menggunakan periode musiman 7 hari.

Hasilnya menunjukkan adanya perubahan level historis serta pola mingguan yang berulang. Namun, residual mengindikasikan bahwa fluktuasi harian belum sepenuhnya dijelaskan oleh kedua komponen tersebut.

Temuan ini menunjukkan bahwa seasonality mingguan relevan untuk diperhatikan dalam forecasting, sementara karakteristik deret waktu masih perlu dievaluasi lebih lanjut melalui stationarity testing.

Stationarity Testing (ADF)



ADF STATIONARITY TEST — ORIGINAL SERIES

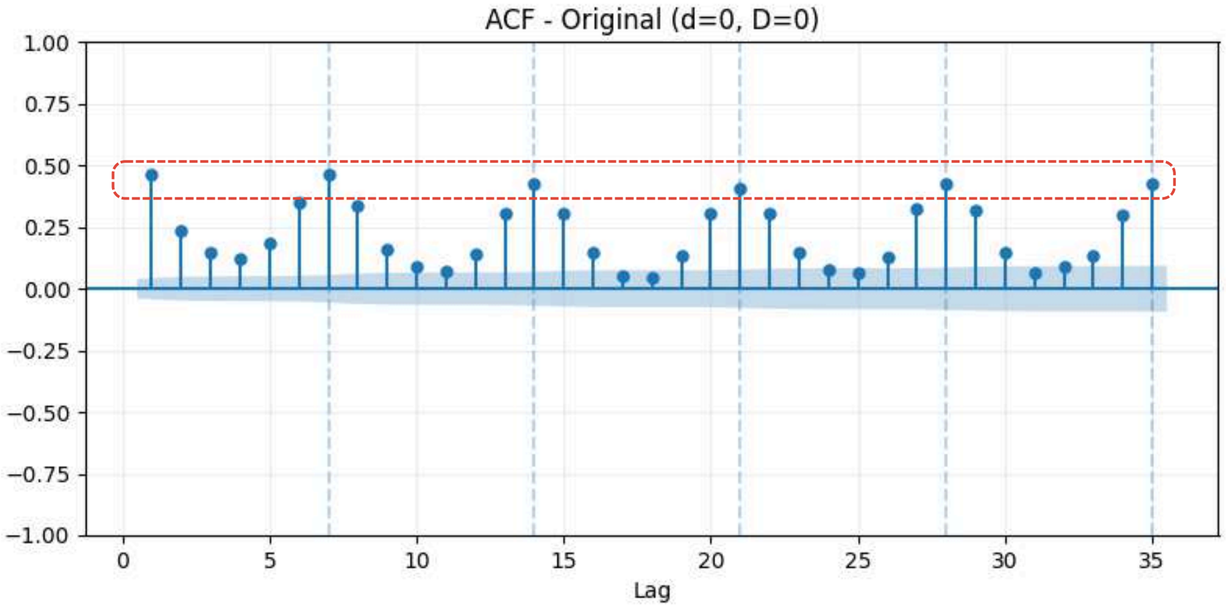
	Metric	Value
0	Observations	2373.000000
1	ADF Statistic	-3.621256
2	p-value	0.005367
3	Lags Used	27.000000

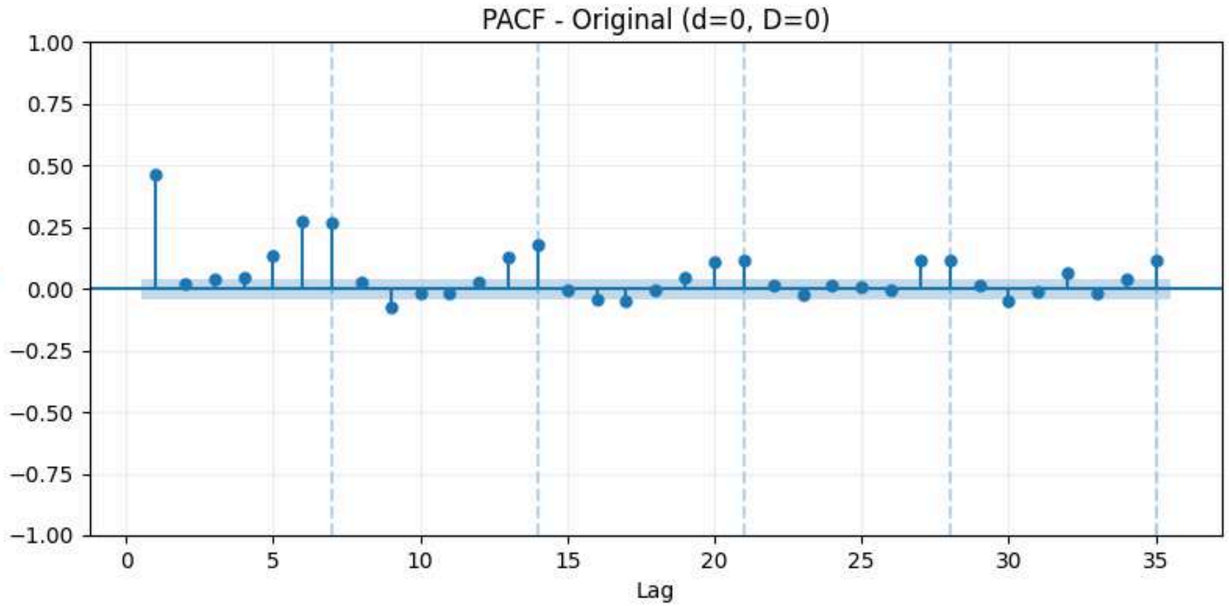
ADF CRITICAL VALUES

	Critical Value
1%	-3.433142
5%	-2.862773
10%	-2.567427

Stationarity testing dilakukan menggunakan Augmented Dickey-Fuller (ADF). Hasil pengujian menunjukkan ADF Statistic sebesar −3,6213 dan p-value 0,00537, lebih kecil dari tingkat signifikansi 0,05. Dengan demikian, data menunjukkan bukti yang mendukung stasioneritas menurut ADF.

ACF & PACF





Analisis ACF dan PACF dilakukan untuk mengidentifikasi hubungan antarobservasi pada berbagai lag serta mengevaluasi kebutuhan differencing. Original series menunjukkan autokorelasi positif pada lag 1 (0,4643) dan lag 7 (0,4619), dengan pola berulang pada lag 14, 21, dan 28 yang memperkuat indikasi seasonality mingguan.

Berdasarkan diagnosis tersebut, perlu pengujian beberapa konfigurasi SARIMA dengan seasonal period tujuh hari, kemudian memilih model terbaik berdasarkan hasil evaluasi forecasting

Pemilihan Model dan Train-Test Split

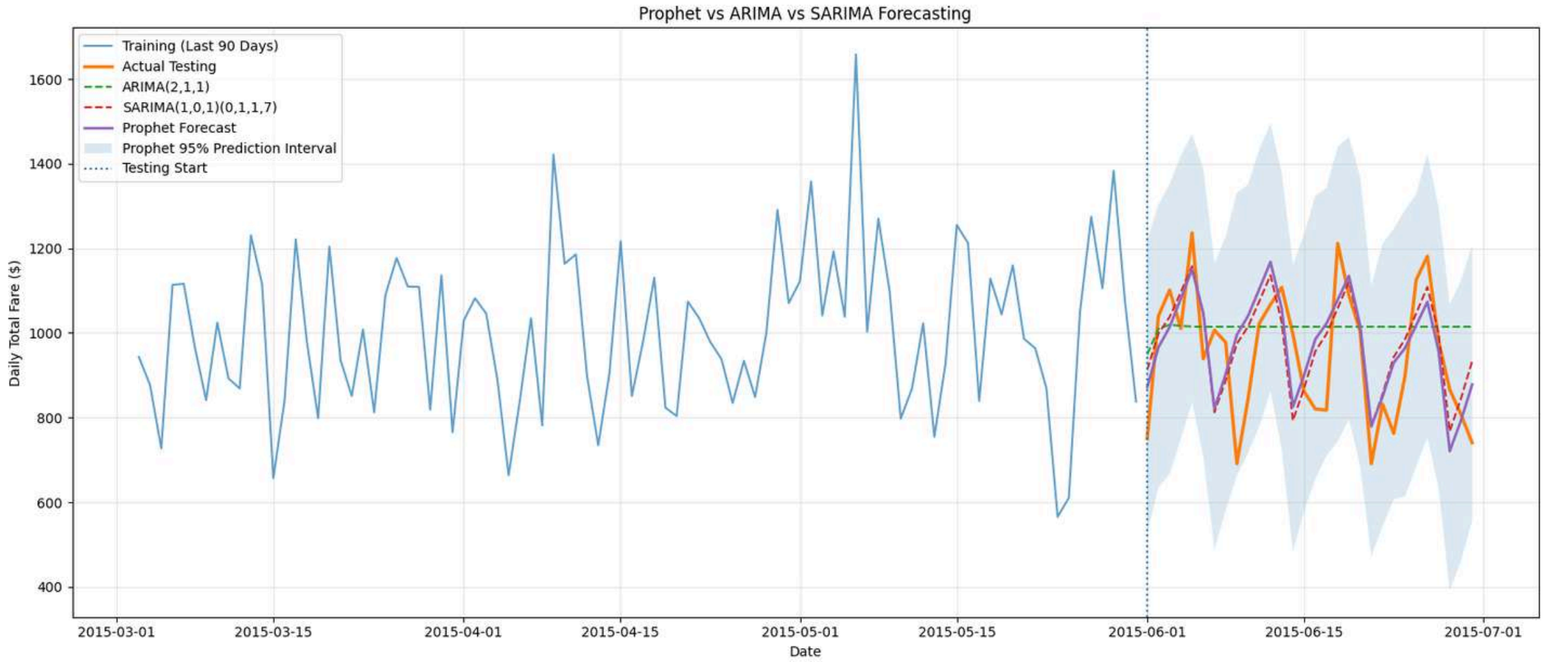
- **Naive Baseline**
  - Digunakan sebagai baseline (standar minimum) untuk mengukur apakah model analitik yang lebih rumit bekerja lebih baik.
- **Seasonal Naive**
  - Model ini dimasukkan karena ditemukan pola mingguan. Ini cara paling sederhana untuk menguji manfaat informasi musiman
- **ARIMA**
  - Model ini membantu menguji kekuatan hubungan hari ke hari secara statistik. Dengan model ini, kita bisa mengetahui apakah pemodelan autokorelasi biasa sudah memadai sebelum menambahkan komponen musiman.
- **SARIMA**
  - pengembangan yang logis dari ARIMA, karena data kita menunjukkan pola mingguan. Seasonal period s = 7 dipilih berdasarkan temuan EDA, STL, dan ACF/PACF, bukan berdasarkan hasil akurasi yang sudah diketahui.
- **Prophet**
  - Dipilih karena mampu mempelajari perubahan tren dan pola musiman, serta relatif tangguh terhadap missing values dan outliers. Model ini digunakan sebagai pembanding untuk mengevaluasi pendekatan forecasting yang lebih fleksibel dalam menghadapi perubahan pola data.

TRAIN-TEST SPLIT SUMMARY

	Dataset	Observations	Start Date	End Date	Percentage (%)
0	Training	2343	2008-12-31	2015-05-31	98.74
1	Testing	30	2015-06-01	2015-06-30	1.26

Dataset time series dibagi secara kronologis menjadi 2.343 observasi training (98,74%) dan 30 observasi testing (1,26%), dengan periode pengujian 1-30 Juni 2015. Pembagian dilakukan tanpa randomisasi untuk menjaga urutan temporal dan mencegah penggunaan informasi masa depan dalam proses training.

Forecasting Model Comparison

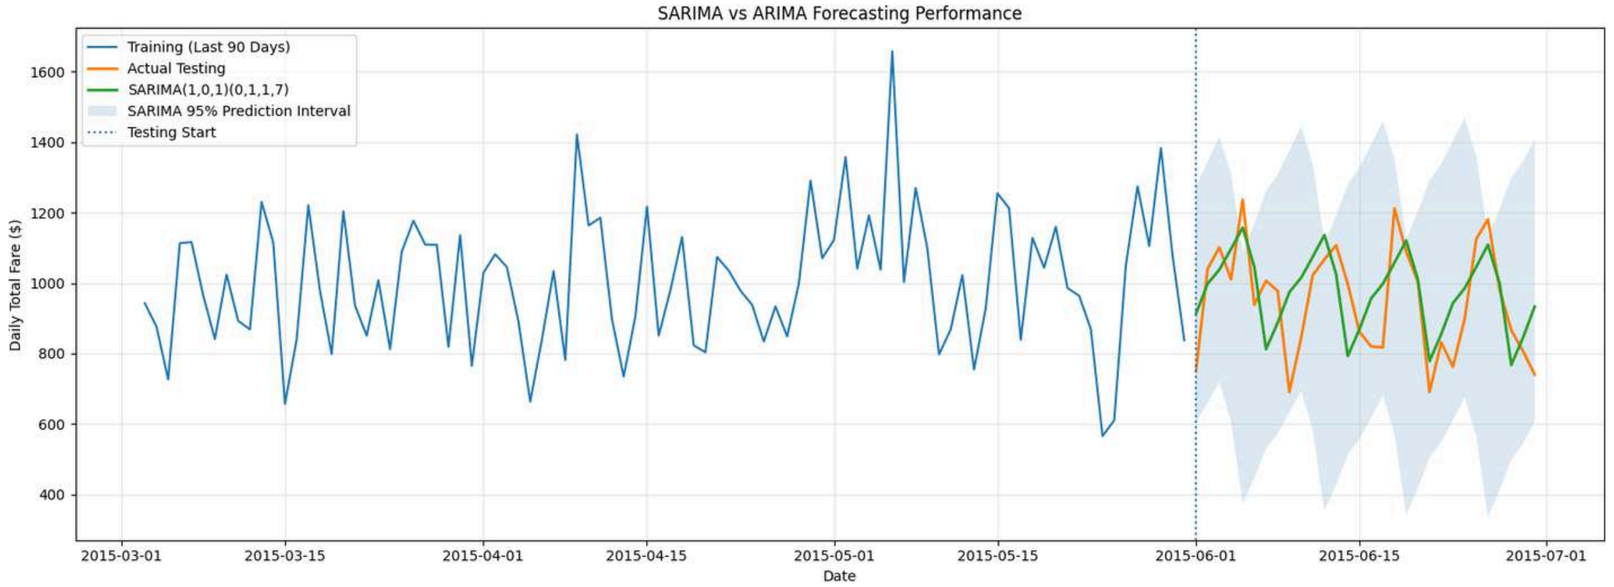


	MAE	RMSE	WAPE (%)
SARIMA(1,0,1)(0,1,1,7)	102.65	122.89	10.81
Prophet	106.32	124.80	11.20
ARIMA(2,1,1)	132.30	162.38	13.94
Naive Baseline	153.48	188.68	16.17

Lima model forecasting dievaluasi menggunakan periode holdout 30 hari yang sama, yaitu Naive, Seasonal Naive, ARIMA, SARIMA, dan Prophet. Performa diukur menggunakan MAE, RMSE, dan WAPE untuk membandingkan besarnya kesalahan prediksi secara konsisten. Hasil evaluasi menunjukkan bahwa **SARIMA(1,0,1)(0,1,1,7) menghasilkan kesalahan terendah pada ketiga metrik, dengan MAE 102,65, RMSE 122,89, dan WAPE 10,81%.** Prophet menunjukkan performa yang mendekati SARIMA dengan WAPE 11,20%, sementara ARIMA dan kedua baseline menghasilkan kesalahan lebih tinggi.

Model Selection & Evaluation

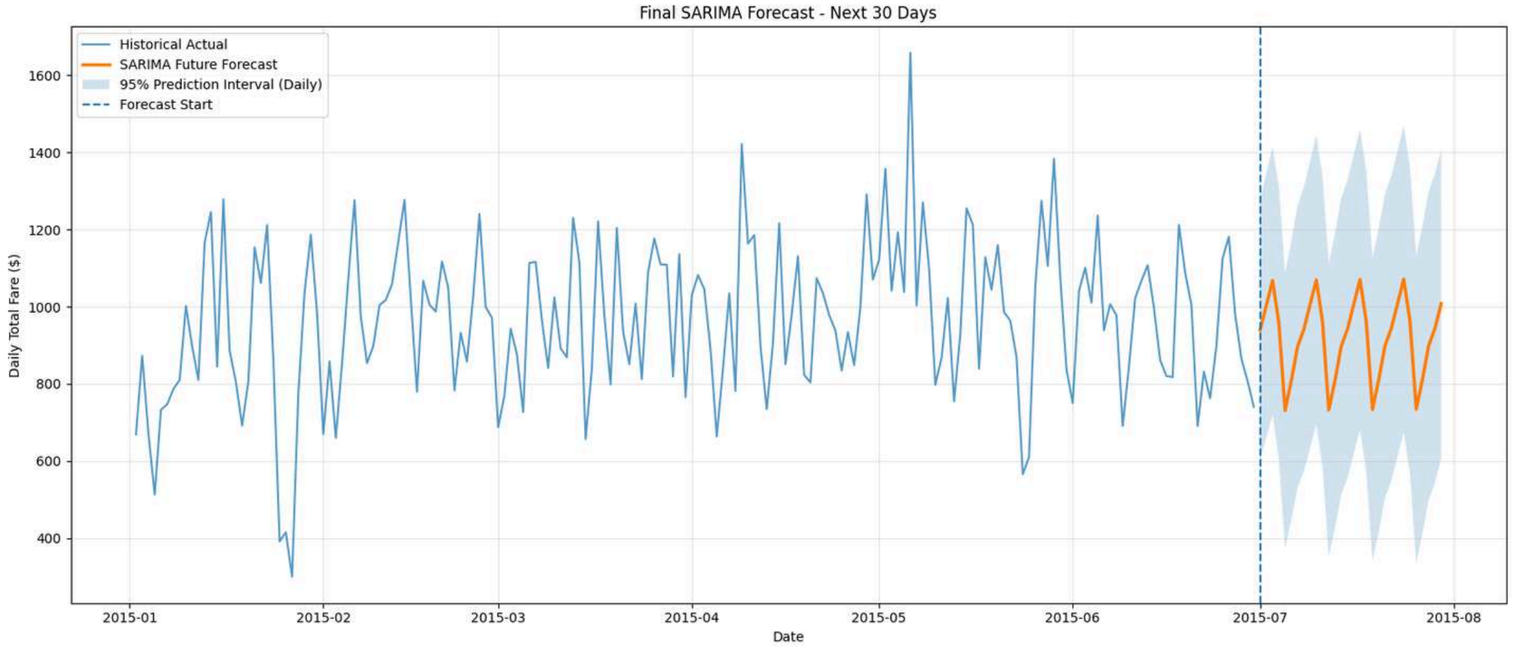
Model	AIC	BIC	MAE	RMSE	WAPE (%)	Converged
SARIMA(1,0,1)(0,1,1,7)	30709.21	30732.23	102.65	122.89	10.81	True
SARIMA(1,1,1)(1,0,1,7)	30858.84	30887.63	123.25	145.78	12.98	True
SARIMA(1,0,1)(1,0,1,7)	31095.24	31129.79	113.10	133.74	11.91	True



Berdasarkan hasil evaluasi holdout Juni 2015, SARIMA(1,0,1)(0,1,1,7) dipilih sebagai model final karena menghasilkan MAE, RMSE, dan WAPE terendah dibandingkan keempat model lainnya. Secara visual, prediksi SARIMA mampu mengikuti pola fluktuasi mingguan dengan lebih baik dibandingkan ARIMA dan Prophet.

Hasil ini menunjukkan bahwa komponen musiman mingguan relevan dalam memodelkan total fare harian. Namun, pemilihan SARIMA didasarkan pada satu periode holdout, sehingga performanya belum dapat digeneralisasikan ke seluruh periode yang berbeda.

Hasil SARIMA Forecasting



	Metric	Value
0	Predicted Total Fare (30 Days)	27628.62
1	Average Daily Predicted Fare	920.95
2	Minimum Daily Predicted Fare	731.12
3	Maximum Daily Predicted Fare	1071.54
4	Previous 30 Days Actual Fare	28481.85
5	Change vs Previous 30 Days (%)	-3.00

Setelah proses evaluasi, SARIMA(1,0,1)(0,1,1,7) dilatih kembali menggunakan seluruh 2.373 observasi historis untuk menghasilkan prediksi total fare selama 30 hari ke depan, yaitu 1–30 Juli 2015. Hasil forecasting menunjukkan **estimasi total fare sebesar $27.628,62**, dengan **rata-rata harian $920,95.** Dibandingkan total fare aktual pada 30 hari sebelumnya sebesar **$28.481,85,** model memproyeksikan **penurunan sebesar 3,00%.** Hasil ini dapat digunakan sebagai referensi awal untuk mengantisipasi perubahan performa fare pada periode mendatang.

Concluation and Recommendations

- **Optimalkan Perencanaan Berdasarkan Pola Mingguan**

  Jumat secara konsisten mencatat rata-rata total fare tertinggi dan Minggu terendah pada setiap tahun pengamatan 2009–2015, dengan selisih keseluruhan sekitar 45,5%. Gunakan pola ini untuk menyusun rencana kapasitas dan promosi berdasarkan hari. Uji coba peningkatan kesiapan layanan pada Jumat dan evaluasi strategi promosi pada Minggu, kemudian ukur hasilnya sebelum diterapkan lebih luas.

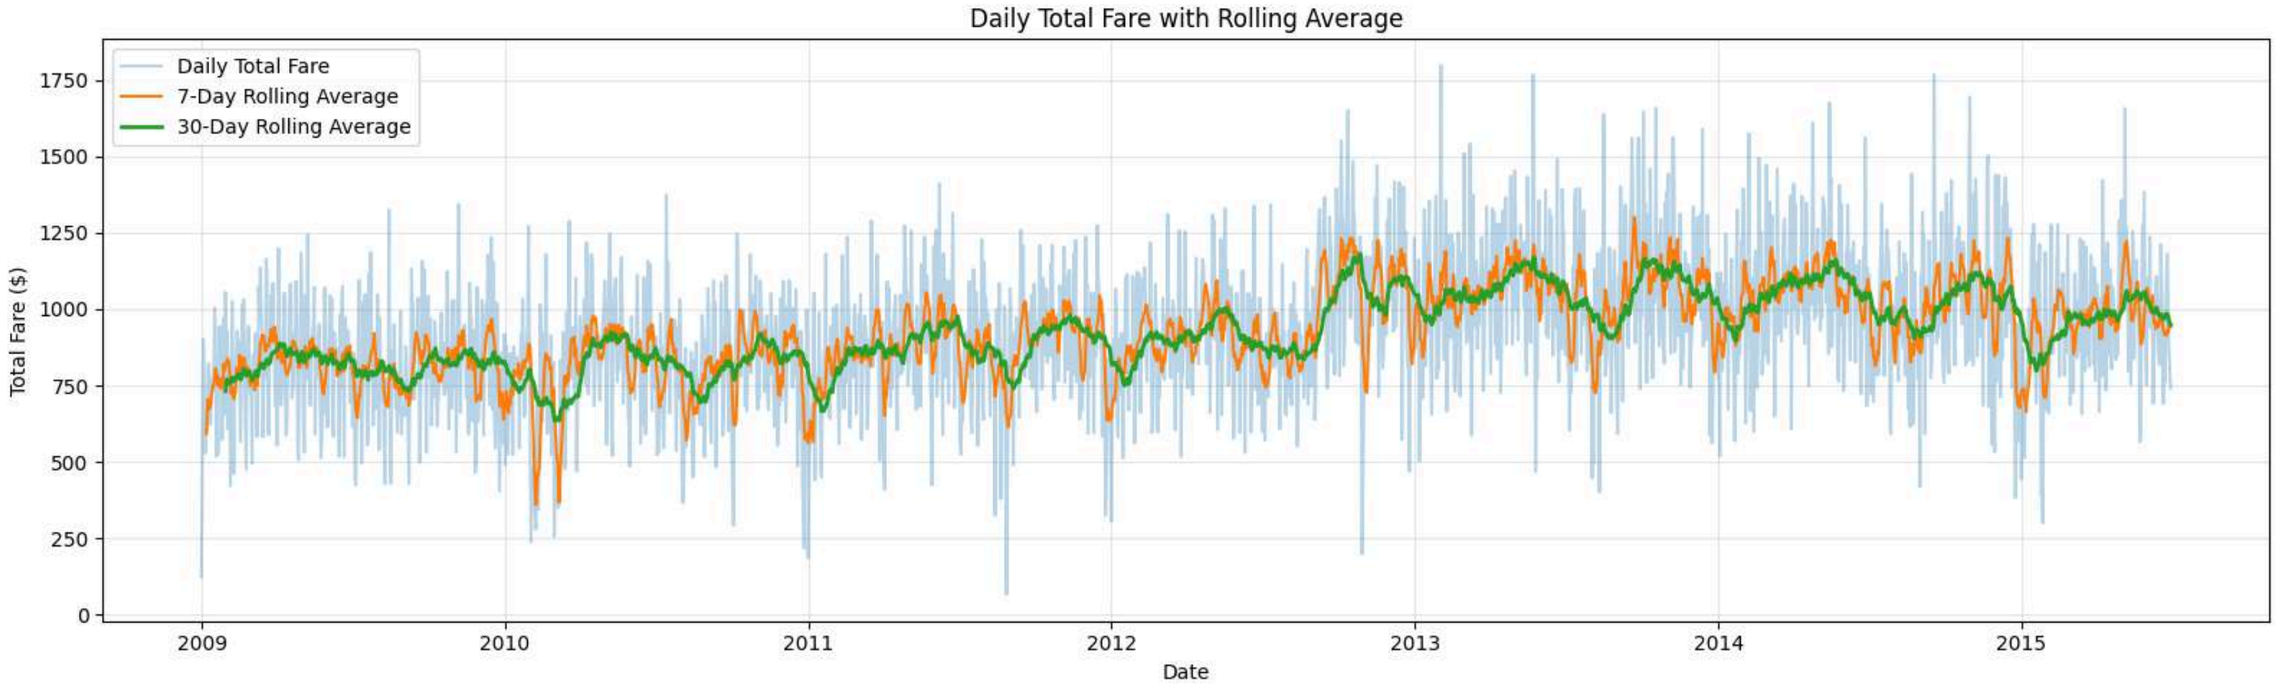
- **Gunakan Model Sebagai Early-Warning System**

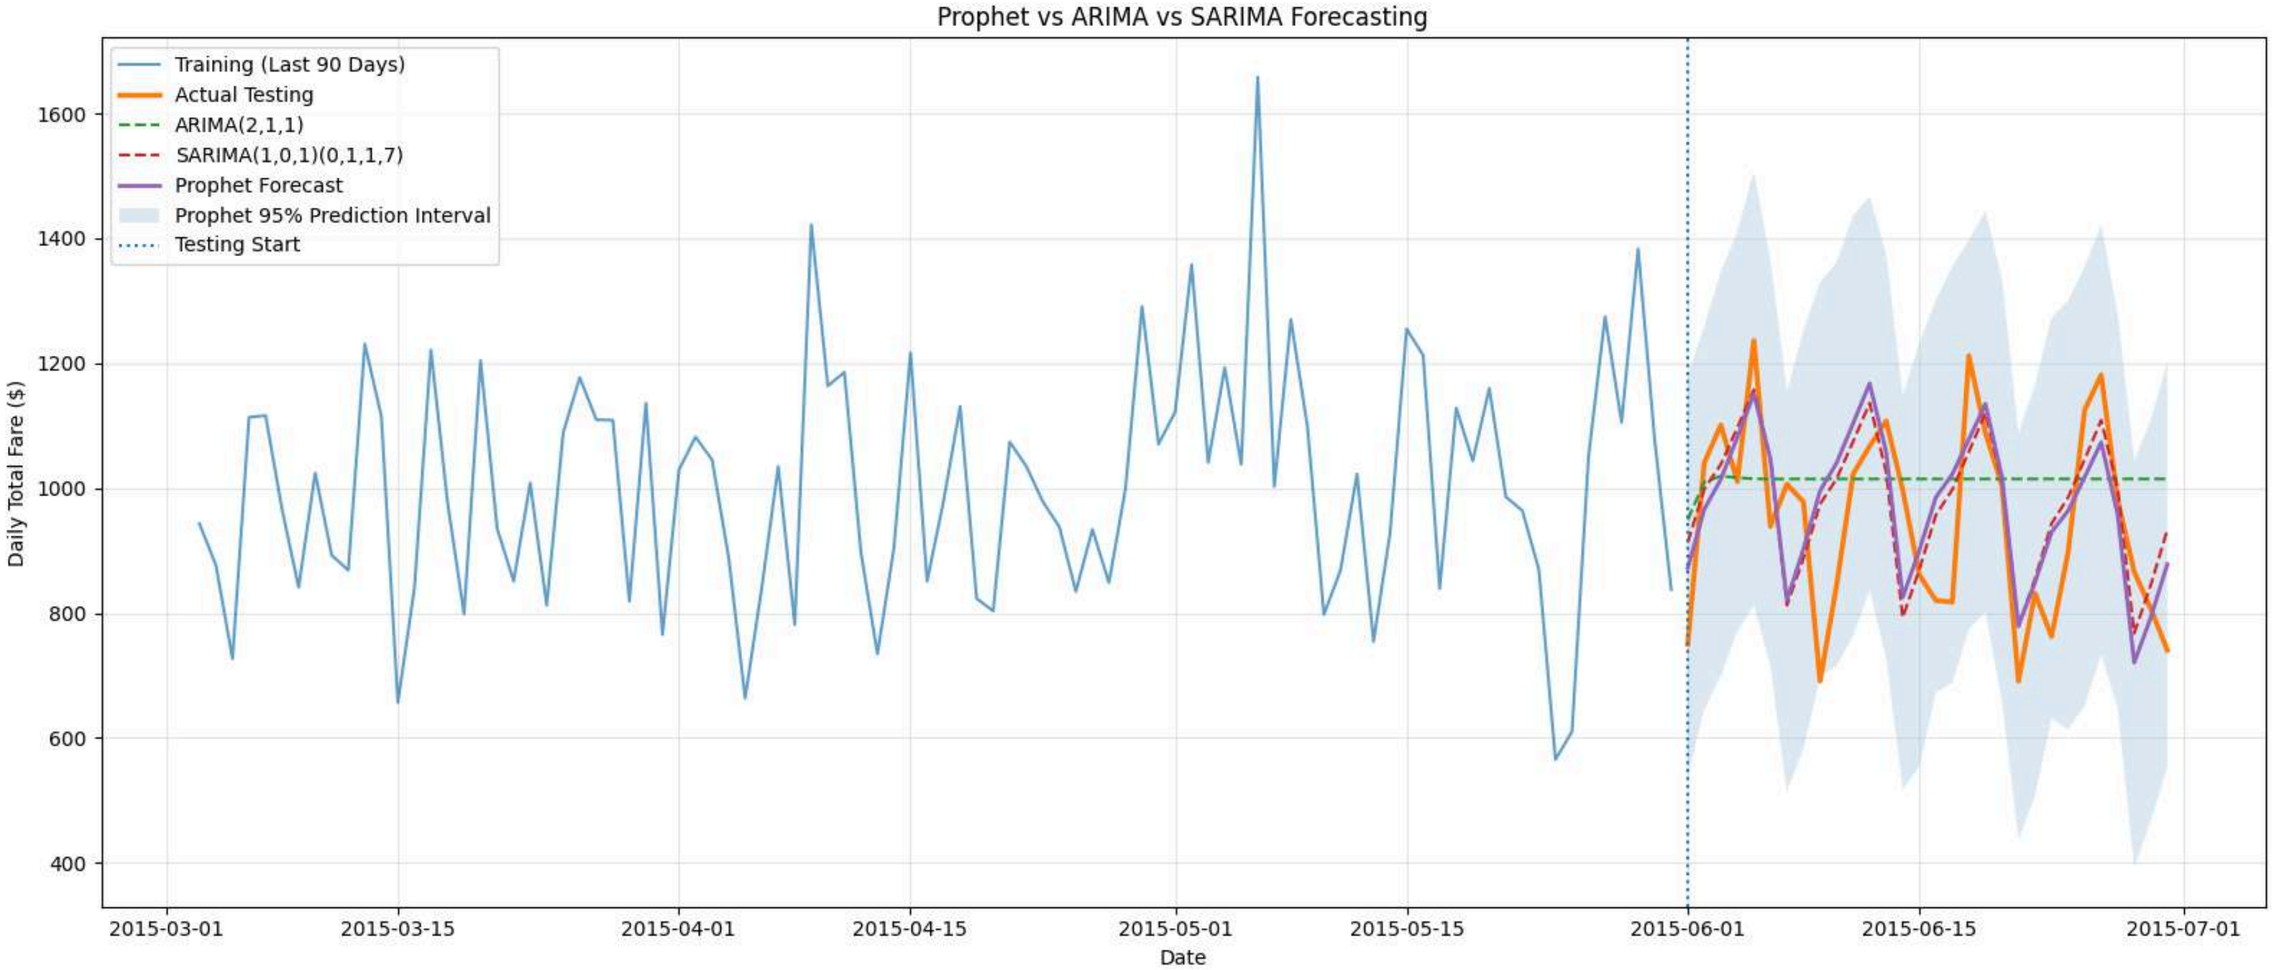
  Buat pemantauan harian yang menampilkan jumlah perjalanan, rata-rata tarif, dan total fare. Ketika terjadi perubahan besar, bandingkan dengan hari yang sama pada minggu sebelumnya untuk mengetahui apakah perubahannya berkaitan dengan jumlah perjalanan, rata-rata tarif, atau pola mingguan.

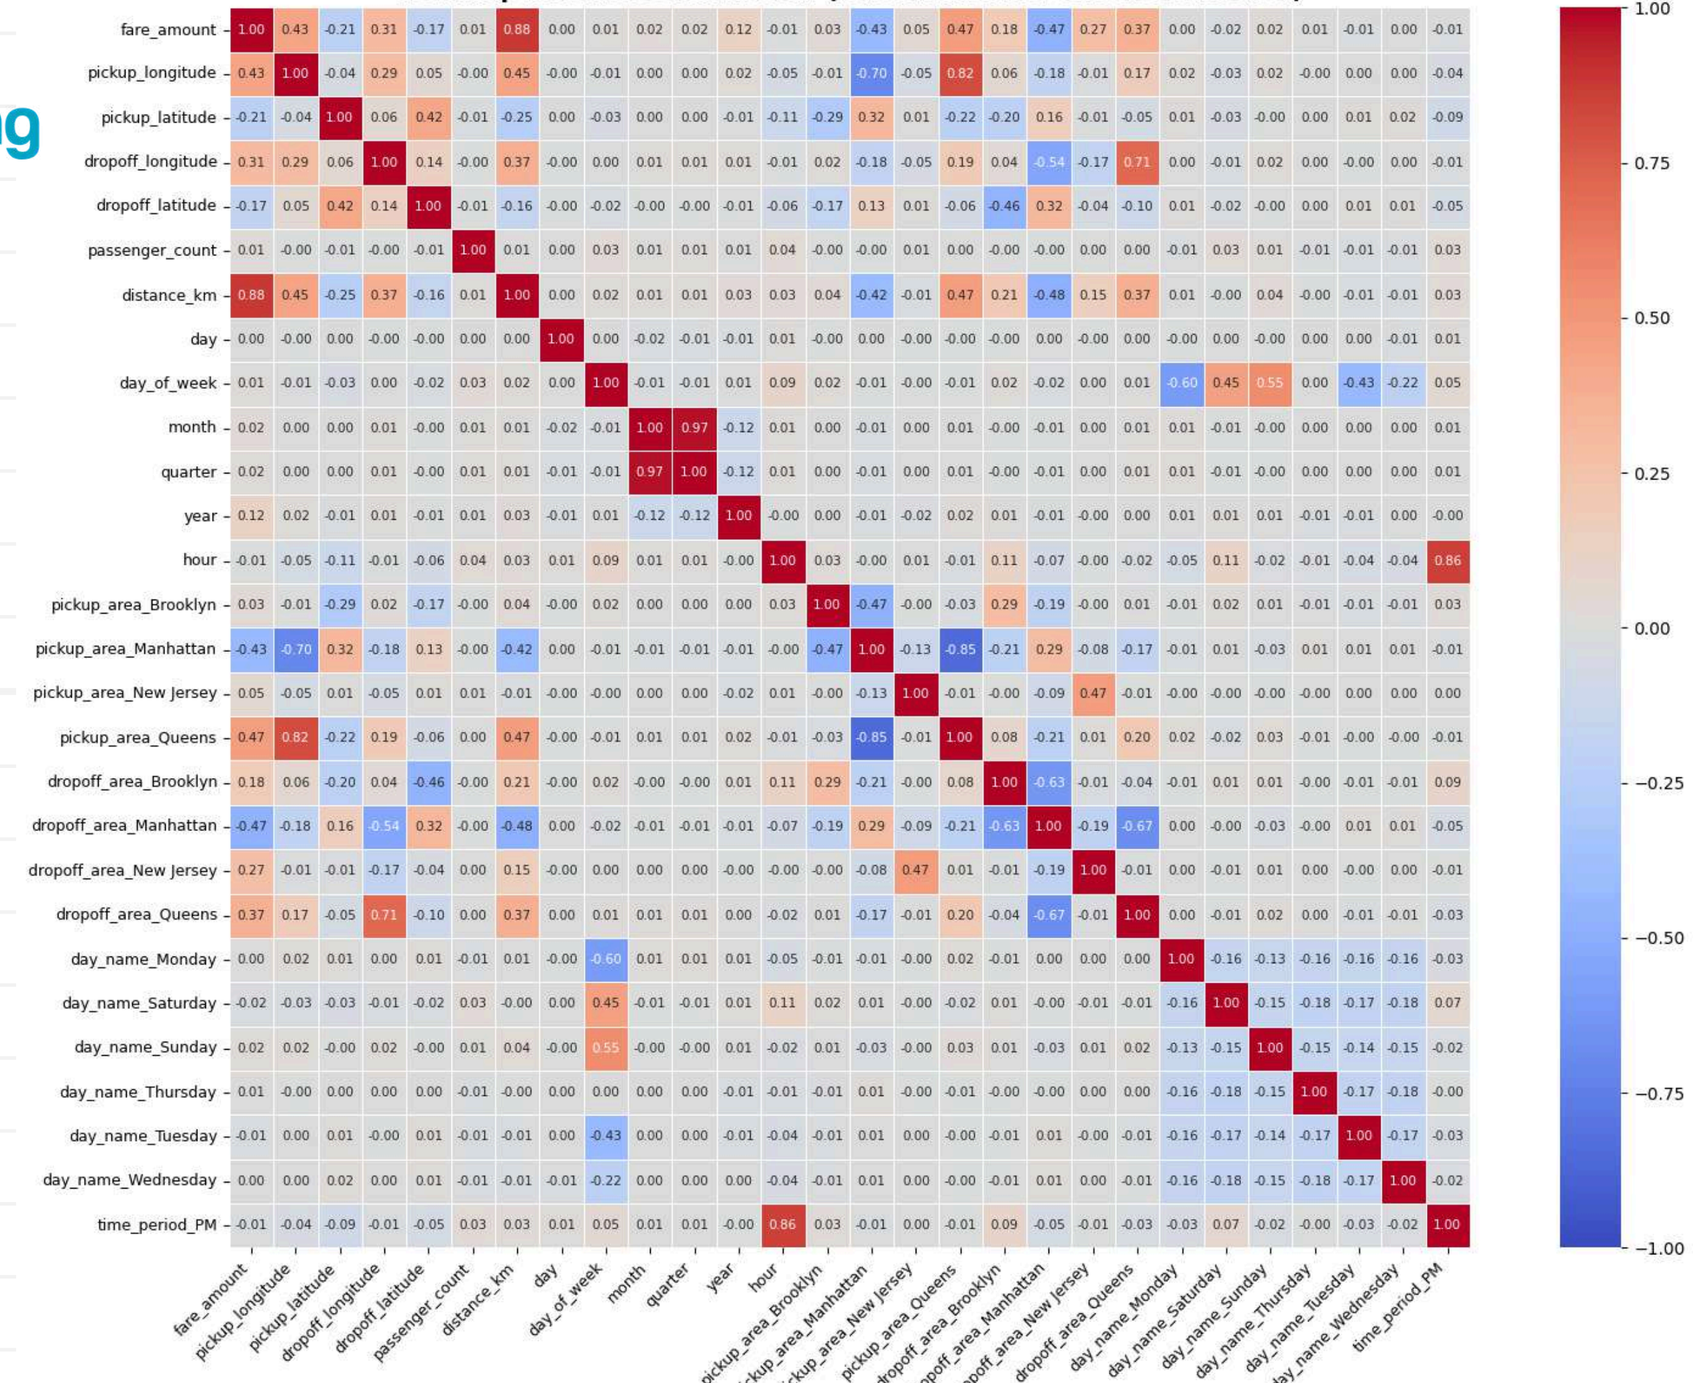
- **Gunakan Forecast dengan Evaluasi Akurasi Berkala**

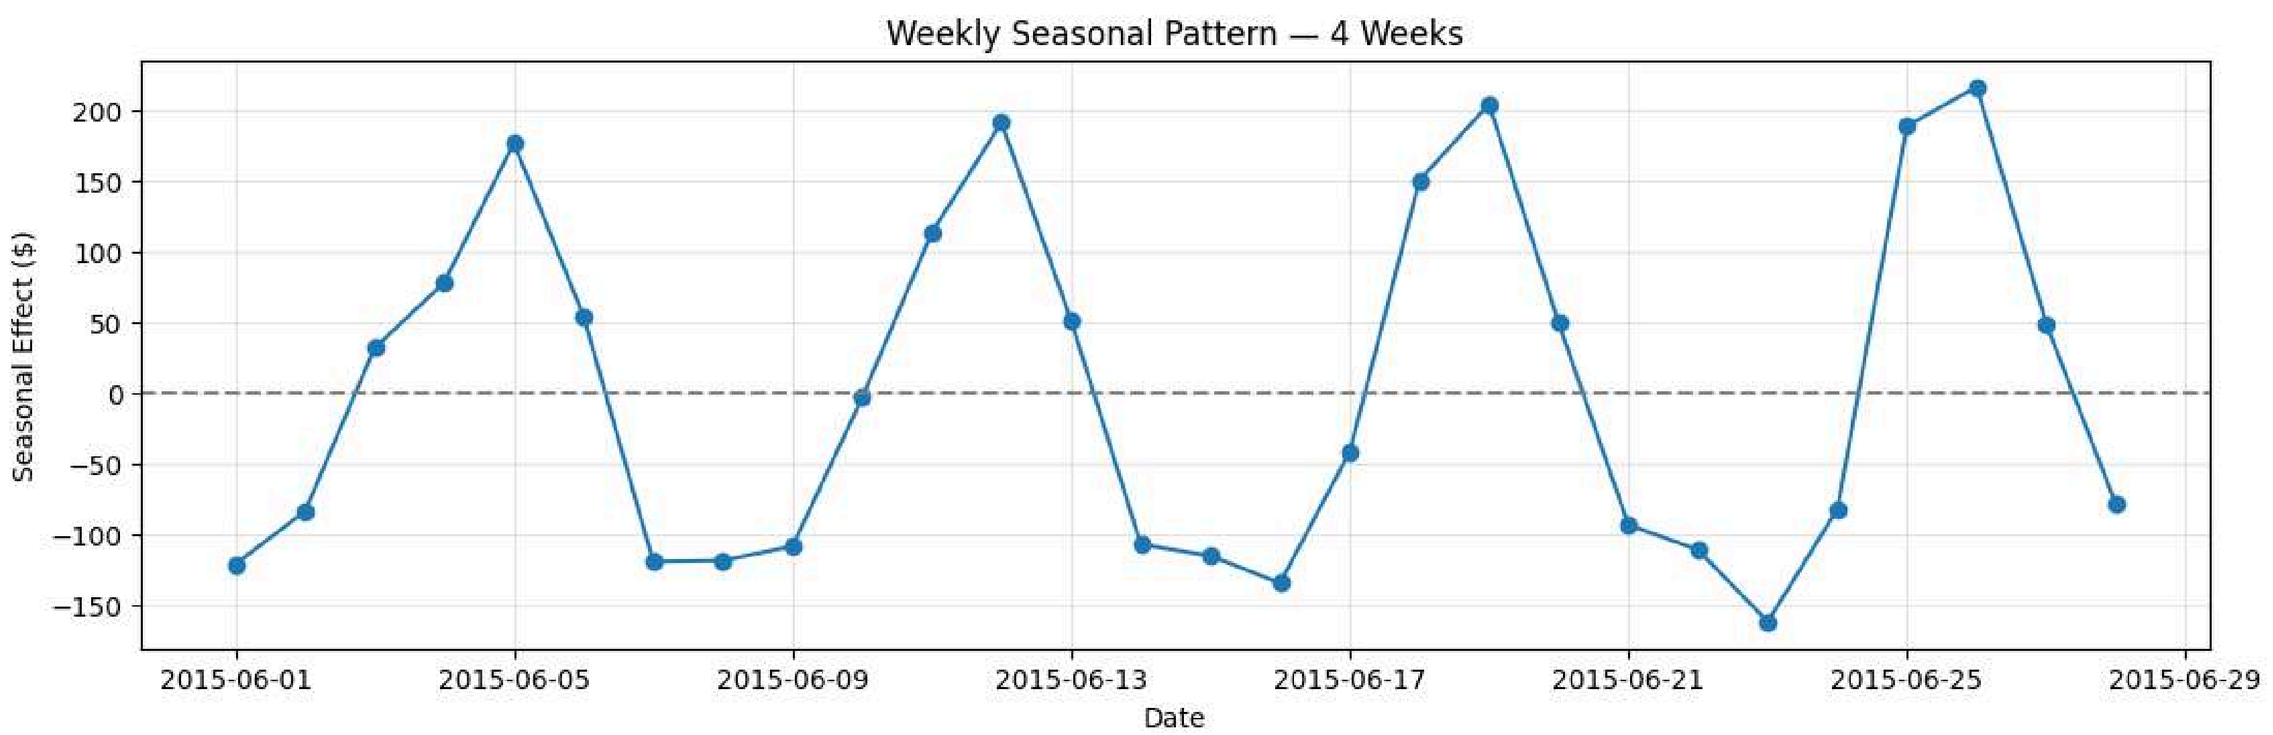
  Gunakan prediksi 30 hari sebagai acuan awal perencanaan, bukan target yang pasti. Pola perjalanan dapat berubah dan data terus akan terupdate secara terus menurus maka dari itu diperlukannya evaluasi model yang sudah dimiliki dan juga mencoba beberapa model yang lain karena tidak ada model yang sempurna sehingga harus terus dibandingkan dengan model yang lain.

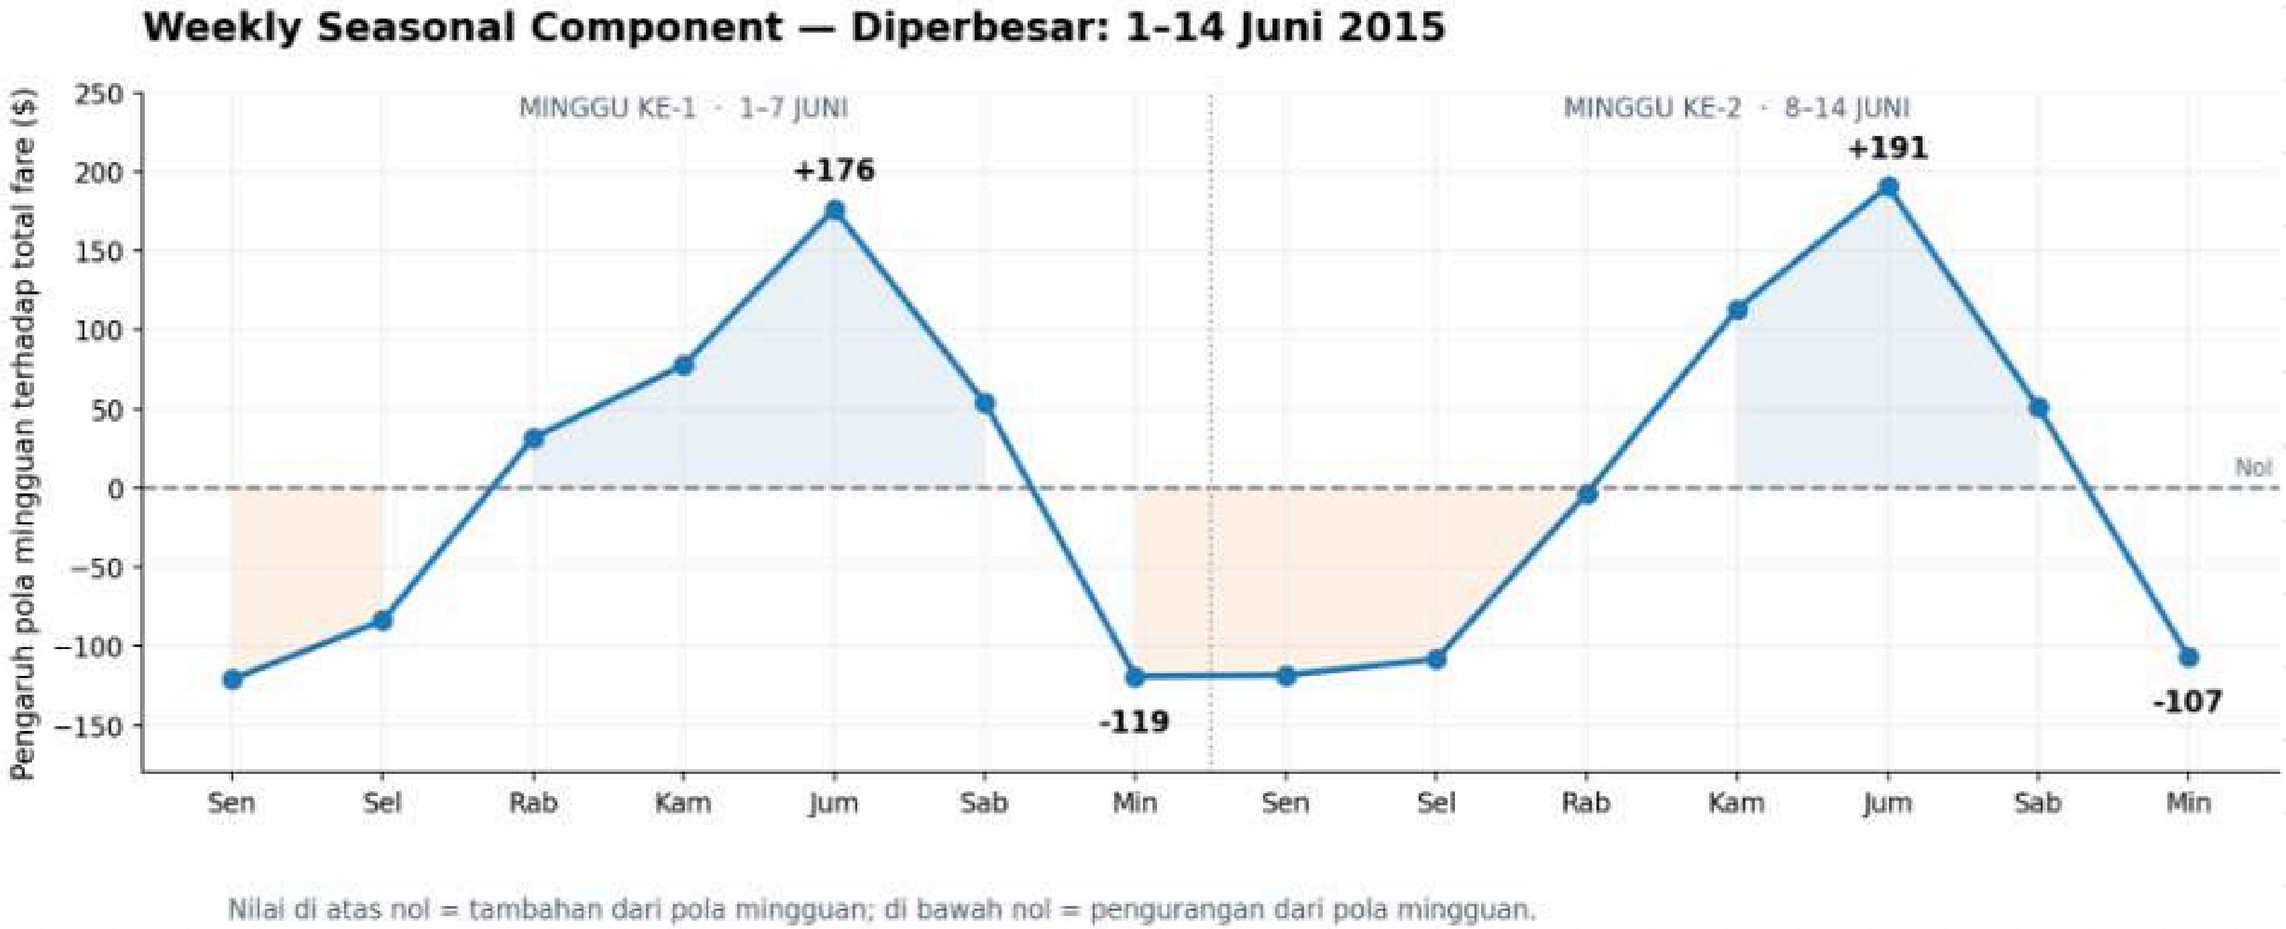

ibimbing
Q&A Session
Canva


Daily Total Fare with Rolling Average
Daily Total Fare
7-Day Rolling Average
30-Day Rolling Average
Total Fare ($)
0
250
500
750
1000
1250
1500
1750
2009
2010
2011
2012
2013
2014
2015
Date

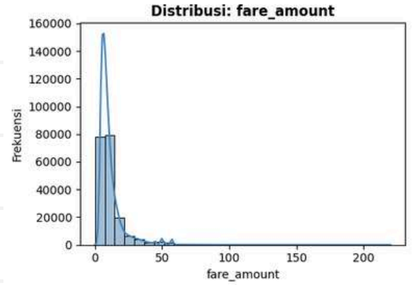

Prophet vs ARIMA vs SARIMA Forecasting
Training (Last 90 Days)
Actual Testing
ARIMA(2,1,1)
SARIMA(1,0,1)(0,1,1,7)
Prophet Forecast
Prophet 95% Prediction Interval
Testing Start
Daily Total Fare ($)
1600
1400
1200
1000
800
600
400
2015-03-01
2015-03-15
2015-04-01
2015-04-15
2015-05-01
2015-05-15
2015-06-01
2015-06-15
2015-07-01
Date

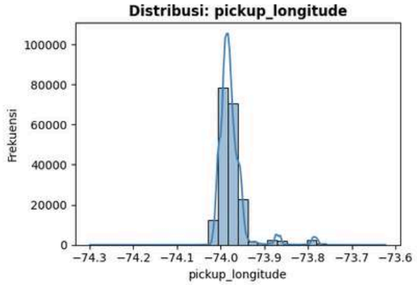

Heatmap Korelasi Seluruh Fitur (Data Numerik & One-Hot Encoded)
fare_amount
pickup_longitude
pickup_latitude
dropoff_longitude
dropoff_latitude
passenger_count
distance_km
day
day_of_week
month
quarter
year
hour
pickup_area_Brooklyn
pickup_area_Manhattan
pickup_area_New Jersey
pickup_area_Queens
dropoff_area_Brooklyn
dropoff_area_Manhattan
dropoff_area_New Jersey
dropoff_area_Queens
day_name_Monday
day_name_Saturday
day_name_Sunday
day_name_Thursday
day_name_Tuesday
day_name_Wednesday
time_period_PM
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00

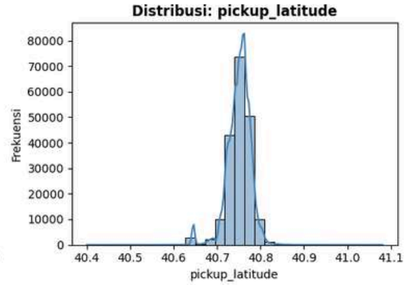

Weekly Seasonal Pattern — 4 Weeks
Seasonal Effect ($)
200
150
100
50
0
−50
−100
−150
2015-06-01
2015-06-05
2015-06-09
2015-06-13
2015-06-17
2015-06-21
2015-06-25
2015-06-29
Date

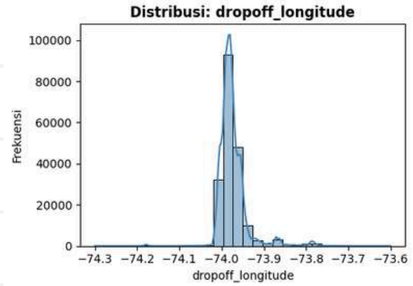


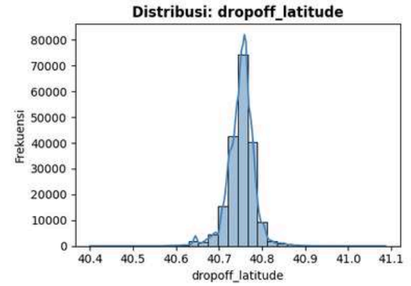
Nilai di atas nol = tambahan dari pola mingguan; di bawah nol = pengurangan dari pola mingguan.

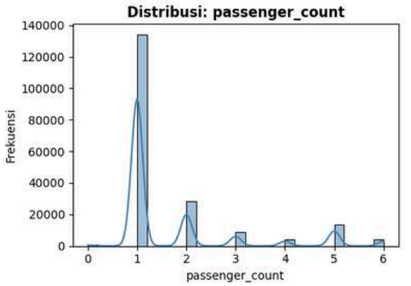

Distribusi: fare_amount
Frekuensi
fare_amount

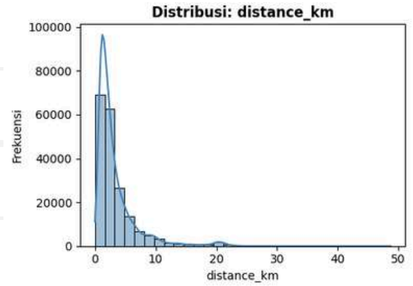

Distribusi: pickup_longitude
Frekuensi
pickup_longitude

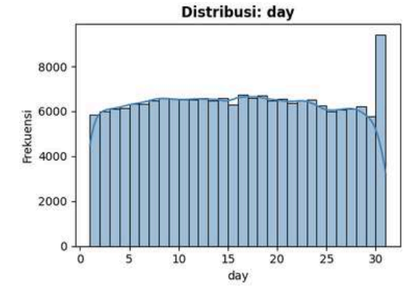

Distribusi: pickup_latitude
Frekuensi
pickup_latitude

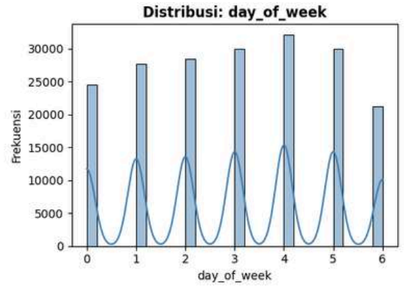

Distribusi: dropoff_longitude
Frekuensi
dropoff_longitude

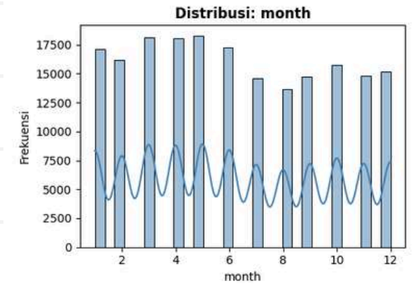

Distribusi: dropoff_latitude
Frekuensi
dropoff_latitude

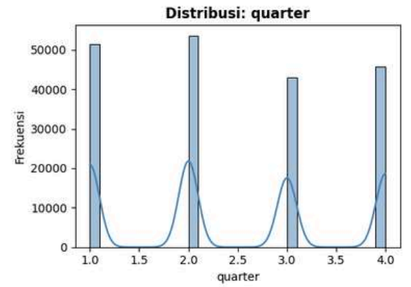

Distribusi: passenger_count
Frekuensi
passenger_count

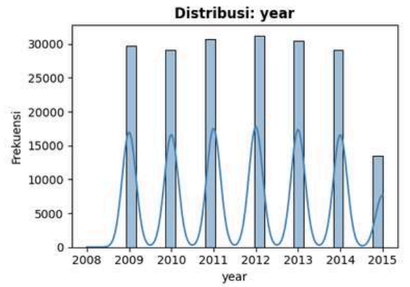

Distribusi: distance_km
Frekuensi
distance_km

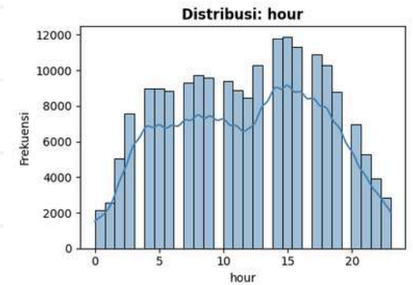

Distribusi: day
Frekuensi
day


Distribusi: day_of_week
Frekuensi
day_of_week


Distribusi: month
Frekuensi
month


Distribusi: quarter
Frekuensi
quarter


Distribusi: year
Frekuensi
year


Distribusi: hour
Frekuensi
hour